

Učenje podsticanjem u okruženjima BipedalWalker-v3 i BipedalWalkerHardcore-v3

Poređenje PPO, SAC i TD3 algoritama i razvoj SAC–LSTM pristupa

Aleksa Mojsić

25. avgust 2026.

Abstract

U radu su ispitani algoritmi PPO, SAC i TD3 za upravljanje dvonožnim robotom u okruženjima BipedalWalker-v3 i BipedalWalkerHardcore-v3. Standardne implementacije algoritama korišćene su kao polazni modeli, dok je za zahtevniju varijantu razvijen SAC agent koji koristi istoriju opservacija, LSTM mrežu i mehanizam za sprečavanje stagnacije. Na standardnom zadatku najbolji prijavljeni srednji rezultat postiže TD3 (299,54), dok PPO i TD3 u sprovedenim eksperimentima nisu uspešno rešili hardcore varijantu. Najbolja sačuvana višeevizodna evaluacija SAC–LSTM modela ostvaruje srednju sirovu nagradu $216,84 \pm 76,06$ u pet epizoda. Dobijeni rezultati pokazuju značajno poboljšanje u odnosu na polazne modele, ali velika varijansa i trening sa jednim glavnim semenom ne omogućavaju zaključak da je zahtevniji zadatak stabilno rešen.

Sadržaj

1	Uvod i cilj projekta	3
2	Okruženje i podaci	3
2.1	Stanja i percepcije	3
2.2	Akcije	3
2.3	Nagrada i terminalna stanja	3
3	Modeli	4
3.1	Polazni modeli	4
3.2	SAC-LSTM model	4
3.3	Mehanizam za sprečavanje stagnacije	5
4	Eksperimentalni protokol	5
5	Rezultati	6
5.1	Standardno okruženje	6
5.2	Polazni modeli na hardcore okruženju	8
5.3	SAC-LSTM eksperimenti	8
6	Analiza grešaka	10
7	Poređenje sa javno prijavljenim rezultatima	11
8	Zaključak i dalji rad	12

1 Uvod i cilj projekta

Učenje podsticanjem posmatra interakciju agenta i okruženja kao niz odluka. Agent na osnovu stanja bira akciju, okruženje vraća nagradu i novo stanje, a cilj je maksimizacija očekivane diskontovane sume nagrada

$$G_t = \sum_{k=0}^{T-t} \gamma^k r_{t+k}, \quad (1)$$

gde je $\gamma \in [0, 1]$ faktor diskontovanja.

Cilj projekta je:

1. poređenje PPO, SAC i TD3 algoritama na standardnom zadatku;
2. ispitivanje prenosa tih pristupa na zahtevniji hardcore zadatak;
3. razvoj sekvencijalnog modela koji koristi istoriju opservacija;
4. analiza uticaja mehanizma za sprečavanje stagnacije na ponašanje agenta.

Glavno istraživačko pitanje glasi: *da li istorija opservacija, LSTM mreža i eksplicitno kažnjavanje stagnacije mogu da poboljšaju ponašanje agenta na okruženju `BipedalWalkerHardcore-v3`?*

2 Okruženje i podaci

Za razliku od nadgledanog učenja, u ovom problemu ne postoji unapred pripremljen skup označenih primera. Podaci za obuku nastaju tokom interakcije agenta sa Gymnasium okruženjem. Svaka tranzicija ima oblik

$$(s_t, a_t, r_t, s_{t+1}, d_t),$$

gde su s_t stanje, a_t akcija, r_t nagrada, a d_t indikator završetka epizode. Tranzicije off-policy algoritama čuvaju se u replay buffer-u i uzorkuju tokom treninga.

2.1 Stanja i percepcije

Opservacija je vektor od 24 realne vrednosti. Sadrži ugao i brzine tela, položaje i ugaone brzine zglobova, kontakte nogu sa podlogom i deset lidar merenja terena. Agent ne dobija sliku niti apsolutne koordinate. U razvijenom pristupu poslednjih 12 opservacija formira sekvencu dimenzije 12×24 .


2.2 Akcije

Akcioni prostor je kontinualan četvorodimenzioni vektor iz intervala $[-1, 1]^4$. Komponente određuju upravljanje motorima oba kuka i oba kolena. Izlaz actor mreže se ograničava na dozvoljeni interval pre prosleđivanja simulatoru.

2.3 Nagrada i terminalna stanja

Pozitivna nagrada podstiče kretanje udesno, dok se potrošnja obrtnog momenta blago kažnjava. Kontakt trupa sa tlom donosi kaznu od -100 . Epizoda se završava padom ili dolaskom do kraja staze, dok se pri dostizanju vremenskog ograničenja prekida. Prema dokumentaciji, standardna varijanta se smatra rešenom sa 300 poena u najviše 1600 koraka, a hardcore varijanta sa 300 poena u najviše 2000 koraka [1].

Hardcore varijanta uvodi dodatne prepreke, poput merdevina, panjeva i jama. Zbog složenijeg terena uvedena je kratka istorija opservacija, kako bi model pri izboru akcije imao informaciju o neposredno prethodnom kretanju i kontaktu sa preprekom. Slika 1 prikazuje determinističke početne kadrove oba okruženja za isto seme. Opservacija, pored prikazanog stanja robota i terena, sadrži deset numeričkih lidar merenja.



Slika 1: Poređenje standardnog okruženja BipedalWalker-v3 i zahtevnijeg okruženja BipedalWalkerHardcore-v3, koje uvodi prepreke poput panjeva, jama i merdevina. Kadrovi su generisani direktno iz Gymnasium okruženja sa semenom 42.

3 Modeli

3.1 Polazni modeli

Nasumična politika predstavlja najjednostavniji oblik upravljanja i služi kao donja referentna vrednost. Njena sačuvana evaluacija na hardcore okruženju iznosi $-109,56 \pm 8,08$ u pet epizoda. Kao polazni modeli korišćene su i standardne implementacije PPO, SAC i TD3 algoritama iz biblioteke Stable-Baselines3 [5].

PPO je on-policy metod koji više puta optimizuje ograničenu surrogate funkciju nad prikupljenim batch-em [2]. SAC je off-policy actor-critic metod koji, pored očekivane nagrade, maksimizuje entropiju politike [3]. TD3 smanjuje precenjivanje Q-vrednosti korišćenjem dva critic modela, zakašnjelih actor ažuriranja i izgladivanja ciljne politike [4].

3.2 SAC-LSTM model

Razvijeni model koristi niz od 12 uzastopnih opservacija. Sekvenca se obrađuje LSTM enkoderom, a dobijena reprezentacija koristi se u actor i critic mrežama. SAC actor daje parametre stohastičke politike, dok dva critic modela aproksimiraju $Q(s, a)$. Ciljna vrednost je


$$y = r + \gamma(1 - d) \left[\min_{i \in \{1,2\}} Q'_i(s', a') - \alpha \log \pi(a'|s') \right]. \quad (2)$$

Actor se optimizuje tako da istovremeno bira akcije velike procenjene vrednosti i održava istraživanje:

$$J_\pi = \mathbb{E} \left[\alpha \log \pi(a|s) - \min_i Q_i(s, a) \right]. \quad (3)$$

Tok odluke prikazan je na Slici 2. Actor bira akciju pri izvršavanju politike, dok se critic modeli i replay buffer koriste tokom treninga.

Tok odluke SAC--LSTM agenta



Slika 2: Poslednjih 12 opservacija, od kojih svaka ima 24 vrednosti, obrađuje LSTM enkoder. SAC actor zatim proizvodi četiri kontinualne akcije za motore kukova i kolena; dva critic modela učestvuju u treningu.

3.3 Mehanizam za sprečavanje stagnacije

Tokom ranih eksperimenata primećeno je da agent može dugo ostati uspravan bez stvarnog napretka. Zbog toga je uveden dodatni mehanizam koji prati horizontalni pomeraj u definisanom vremenskom prozoru. Nakon početnog perioda bez provere, stagnacija se kažnjava, a posle zadatog broja uzastopnih detekcija epizoda se prekida. Izmenjena funkcija nagrade koristi se isključivo tokom treninga, dok se za konačno poređenje prijavljuje originalna, sirova nagrada okruženja.

4 Eksperimentalni protokol

Implementacija koristi Python, Gymnasium, Stable-Baselines3, NumPy i PyTorch. U glavnim eksperimentima korišćeno je seme 42. Pri evaluaciji se koristi deterministička akcija modela, dok se početna semena okruženja menjaju između epizoda. Standardni eksperimenti imaju 300 000 koraka treninga i pet evaluacionih epizoda. SAC-LSTM model koristi istoriju dužine 12, `frame_skip=2` i periodično čuvanje najboljih stanja modela.

Srednja vrednost i standardna devijacija nagrade računaju se kao

$$\bar{r} = \frac{1}{n} \sum_{i=1}^n r_i, \quad \sigma_r = \sqrt{\frac{1}{n} \sum_{i=1}^n (r_i - \bar{r})^2}.$$



5 Rezultati

5.1 Standardno okruženje

Tabela 1: Prijavljeni rezultati na BipedalWalker-v3, 300 000 koraka, seme 42 i pet evaluacionih epizoda.

Algoritam	Srednja nagrada	Std. dev.	Srednja dužina
PPO	125,28	131,29	989,6
SAC	282,08	0,91	1181,6
TD3	299,54	0,46	797,0

TD3 ostvaruje najveću srednju nagradu i najmanju standardnu devijaciju, SAC postiže visok i ujednačen rezultat, dok PPO pokazuje znatno veću varijabilnost. Slika 3 poredi ove rezultate sa SB3 referentnim modelima i javnim prijavama iz Hugging Face skupa leaderboard rezultata [7]. Rangovi na slici izračunati su samo prema srednjoj nagradi, pa predstavljaju orijentaciono, a ne strogo kontrolisano poređenje.



Slika 3: Poređenje na standardnom zadatku. Gore: PPO, SAC i TD3 iz ovog rada naspram odgovarajućih SB3 referentnih modela. Dole: prvih 20 javnih prijava i približan položaj modela iz ovog rada prema srednjoj nagradi. Različiti protokoli treninga i evaluacije ograničavaju direktno rangiranje.

5.2 Polazni modeli na hardcore okruženju

Tabela 2: Polazni modeli na hardcore zadatku.

Model	Budžet	n	Nagrada	Tumačenje
Nasumična politika	–	5	$-109,56 \pm 8,08$	Donja referentna vrednost.
PPO	100 000 000	5	$-98,81 \pm 20,90$	Rezultat ostaje nizak, uz česte rane padove.
TD3	300 000	5	$-116,88 \pm 24,80$	Svih pet epizoda dostiže 2000 koraka, ali bez značajnog napretka.

Dužina epizode sama po sebi nije dovoljna za procenu uspešnosti, jer TD3 u svih pet evaluacija dostiže vremensko ograničenje bez značajnog napretka. Zbog toga su, pored numeričkih rezultata, analizirani i odgovarajući video-snimci.

5.3 SAC–LSTM eksperimenti


Tabela 3: Rezultati SAC–LSTM pristupa na hardcore zadatku.

Eksperiment	Koraci politike	n	Srednja sirova nagrada	Značenje
Početni SAC–LSTM	218 923	1	$-31,64$	Pojedinačna evaluacija ukazuje na poboljšanje, ali nije dovoljna za pouzdan zaključak.
SAC–LSTM sa mehanizmom protiv stagnacije	927 369	20	$40,01 \pm 67,98$	Prva evaluacija sa pozitivnom srednjom sirovom nagradom.
Nastavljeni trening SAC–LSTM modela	1 920 280	5	$160,90 \pm 113,97$	Odvojena evaluacija sa sačuvanim video-snimcima.
Stanje modela nakon 4600 epizoda	1 357 542	5	$216,84 \pm 76,06$	Najbolja sačuvana višepizodna evaluacija za koju su dostupne pojedinačne nagrade.


Broj koraka politike dobijen je sabiranjem stvarno zabeleženih dužina trening epizoda, bez evaluacionih epizoda. Veličina mini-batch-a od 64 ne množi ovaj broj, jer se uzorci za ažuriranje ponovo uzimaju iz replay buffer-a. Uz `frame_skip=2`, stanje nakon 4600 epizoda zato odgovara 1 357 542 odluke politike i najviše 2 715 084 koraka simulatora.

Tokom treninga je zabeležena i periodična evaluacija sa srednjom nagradom 239,39 u 20 epizoda. Kako pojedinačne nagrade i standardna devijacija za ovu proveru nisu sačuvane, rezultat se ne koristi kao glavni rezultat u tabeli niti kao osnova za poređenje varijabilnosti.

Za najbolju sačuvanu višepizodnu evaluaciju stanja modela nakon 4600 epizoda pojedinačne sirove nagrade su 291,39, 197,40, 217,92, 292,21 i 85,28. Slika 4 pokazuje da dve epizode dostižu rezultat blizak granici od 300 poena, dok razlika između epizoda ukazuje na osetljivost politike na konkretan raspored terena.




Slika 4: Pojedinačne sirove nagrade stanja modela nakon 4600 epizoda. Dve evaluacije ostvaruju rezultat blizak 300 poena, ali razlika među epizodama pokazuje da politika još nije dovoljno stabilna.



Slika 5: Razvoj sačuvanih višeevizodnih evaluacija na hardcore zadatku. Vertikalne linije predstavljaju standardnu devijaciju, a n broj evaluacionih epizoda. Periodični rezultat 239, 39 nije prikazan kao ravnopravan rezultat jer nisu sačuvane pojedinačne nagrade.

Na Slici 5 prikazane su evaluacije za koje su dostupni broj epizoda i standardna devijacija.

Sačuvani logovi omogućavaju i prikaz promene nagrade tokom treninga. Slika 6 prikazuje početni trening do epizode 3200 i njegov nastavak iz sačuvanog stanja modela. X-osa prikazuje kumulativne korake politike. Zbog podešavanja `frame_skip=2`, jedan korak politike obuhvata do dva koraka simulatora.



Slika 6: Sirova nagrada tokom treninga, pokretni prosek od 100 epizoda i periodične evaluacije SAC-LSTM modela. Vertikalna linija označava nastavak treninga iz stanja sačuvanog nakon epizode 3200.

6 Analiza grešaka

Najvažniji uočeni režimi neuspeha su:

- **rani pad** — PPO često gubi ravnotežu pre ostvarenog značajnijeg napretka;
- **stagnacija** — TD3 može ostati uspravan do vremenskog ograničenja bez uspešnog savladavanja prepreka;
- **lokalni optimum** — javljaju se stabilni obrasci oscilovanja koji ne dovode do napretka;
- **osetljivost na teren** — SAC-LSTM u nekim evaluacijama prolazi veći deo staze, dok u drugim rano prestaje da napreduje;
- **razlika između sirove i oblikovane nagrade** — dodatne kazne i prekidi pomažu tokom treninga, zbog čega se konačni zaključci zasnivaju na originalnoj nagradi okruženja.

Video-snimci daju direktnu kvalitativnu potvrdu tri različita režima ponašanja (Slika 7). Izabrani kadrovi vezani su za konkretne JSON evaluacije i semena.




Slika 7: Reprezentativni kadrovi iz sačuvanih evaluacija: (a) PPO, najgora epizoda za seme 44, neposredno pre ranog pada; (b) TD3, najbolja epizoda za seme 46, u kojoj agent ostaje kod prve jame do vremenskog limita; (c) SAC-LSTM, seme 700042 i sirova nagrada 293, 44, nakon prolaska preko više prepreka. Poslednji primer je skoro uspešna, ali ne formalno rešena epizoda.

Rani pad PPO agenta ukazuje na nedovoljno stabilnu kontrolu ravnoteže. Kod TD3 agenta položaj se gotovo ne menja između 15. i 30. sekunde snimka, što pokazuje zašto dužina epizode od 2000 koraka nije dokaz napretka. SAC–LSTM kadar potvrđuje delimično korisnu politiku za prelazak prepreka, ali raspodela nagrada na Slici 4 pokazuje da ta strategija nije dovoljno robusna između evaluacionih semena.

Mehanizam za sprečavanje stagnacije direktno utiče na epizode u kojima agent ne ostvaruje horizontalni napredak, dok LSTM omogućava da odluka zavisi od kratke istorije kretanja. Nakon uvođenja ovih izmena prvi put je dobijena pozitivna srednja sirova nagrada u višeevizodnoj evaluaciji. Ipak, bez kontrolisanog ablacionog eksperimenta na više nezavisnih trening semena nije moguće precizno izdvojiti doprinos svake komponente.

7 Poređenje sa javno prijavljenim rezultatima

Pored međusobnog poređenja obučanih modela, rezultate je korisno posmatrati i u odnosu na javne prijave na OpenAI Gym leaderboard-u [6]. Za hardcore zadatak prag rešavanja iznosi prosečno 300 poena tokom 100 uzastopnih epizoda. Zbog toga jedna epizoda sa nagradom bliskom 300 ne predstavlja dokaz da je zadatak stabilno rešen. Leaderboard sadrži rezultate za verzije v2 i v3, ali one nisu potpuno ekvivalentne zbog izmene lider opservacija u verziji v3. Slika 8 zato koristi samo javne prijave za verziju korišćenu u ovom radu.



Stubici prikazuju srednju nagradu, a crne linije jednu standardnu devijaciju kada je dostupna. Javne prijave nemaju potpuno ujednačen evaluacioni protokol, pa poređenje služi kao referentni okvir.

Slika 8: Izabrani javno prijavljeni rezultati za BipedalWalkerHardcore-v3 i eksperimenti ovog rada. Crne linije predstavljaju jednu standardnu devijaciju kada je dostupna. Glavni rezultat ovog rada je stanje nakon 4600 epizoda sa $216,84 \pm 76,06$ u pet evaluacionih epizoda.

Prikazani javni rezultati pokazuju da se zadatak može rešiti različitim porodicama algoritama: on-policy PPO pristupom [2], off-policy SAC pristupom [3], kao i TD3 varijantom proširenom forward-looking mehanizmom. Prema tome, rekurentna memorija nije neophodan uslov za rešavanje okruženja. U ovom radu LSTM ima drugačiju ulogu: modelu daje kratak vremenski kontekst, dok mehanizam protiv stagnacije smanjuje broj epizoda u kojima agent ostaje kod prepreke bez napretka.

Najbolja sačuvana višepizodna evaluacija ovog rada, $216,84 \pm 76,06$, niža je od javno prijavljenih proseka iznad 300. Dve od pet epizoda ostvaruju 291,39 i 292,21 poena, što potvrđuje da je naučeno korisno ponašanje, ali velika standardna devijacija pokazuje da ono nije dovoljno robusno za različite konfiguracije terena. Rezultat se zato tumači kao parcijalno naučena politika, a ne kao rešen hardcore zadatak.

Direktno rangiranje ipak bi bilo metodološki nepouzdan. Model ovog rada evaluiran je u pet epizoda, dok formalni kriterijum zahteva 100, a za deo leaderboard prijava potpun evaluacioni protokol nije naveden. Ni broj trening epizoda nije potpuna mera budžeta: stanje modela nakon 4600 epizoda odgovara 1 357 542 koraka politike, dok za javne prijave nisu dosledno dostupni broj koraka, `frame_skip` i drugi detalji. Leaderboard zato služi kao referentni okvir za procenu preostalog jaza, a ne kao strogo kontrolisan eksperiment.

8 Zaključak i dalji rad

Na standardnom BipedalWalker-v3 zadatku najbolji prijavljeni rezultat ostvaruje TD3 sa srednjom nagradom 299,54, dok SAC postiže nešto niži, ali veoma stabilan rezultat. Prenos standardnih pristupa na BipedalWalkerHardcore-v3 pokazao se znatno zahtevnijim: PPO ostvaruje niske nagrade uz česte padove, dok TD3 može da ostane uspravan do vremenskog ograničenja bez značajnog napretka.

Uvođenjem istorije od 12 opservacija, LSTM enkodera i mehanizma za sprečavanje stagnacije dobijeno je jasno poboljšanje. Najbolja sačuvana višepizodna evaluacija ostvaruje $216,84 \pm 76,06$, pri čemu dve od pet epizoda dostižu rezultat blizak 300 poena. Ipak, velika razlika između pojedinačnih epizoda pokazuje da politika još nije dovoljno robusna da bi se hardcore zadatak smatrao stabilno rešenim.

Za dalji rad potrebno je ponoviti trening sa više nezavisnih seed-ova, izjednačiti budžet interakcija između modela i sve modele evaluirati na istom skupu test semena. Posebno je značajno sprovesti ablaciono poređenje modela bez LSTM komponente, bez mehanizma protiv stagnacije i sa obe komponente, kako bi se izdvojio njihov pojedinačni doprinos. Pored srednje nagrade i standardne devijacije, korisno je pratiti procenat epizoda sa rezultatom većim ili jednakim 300, kao i prepreke na kojima se agent najčešće zaustavlja.

Literatura

- [1] Farama Foundation, *Bipedal Walker — Gymnasium Documentation*. https://gymnasium.farama.org/environments/box2d/bipedal_walker/
- [2] J. Schulman, F. Wolski, P. Dhariwal, A. Radford i O. Klimov, *Proximal Policy Optimization Algorithms*, 2017. <https://arxiv.org/abs/1707.06347>
- [3] T. Haarnoja, A. Zhou, P. Abbeel i S. Levine, *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor*, ICML, 2018. <https://proceedings.mlr.press/v80/haarnoja18b.html>
- [4] S. Fujimoto, H. van Hoof i D. Meger, *Addressing Function Approximation Error in Actor-Critic Methods*, ICML, 2018. <https://proceedings.mlr.press/v80/fujimoto18a.html>

- [5] A. Raffin et al., *Stable-Baselines3: Reliable Reinforcement Learning Implementations*, JMLR, 2021. <https://www.jmlr.org/papers/v22/20-1364.html>
- [6] OpenAI Gym, *Leaderboard*, GitHub Wiki. <https://github.com/openai/gym/wiki/Leaderboard>
- [7] Hugging Face, *Deep Reinforcement Learning Course Leaderboard Data: BipedalWalker-v3*. <https://huggingface.co/datasets/huggingface-projects/drlc-leaderboard-data>